

IA e Data Science: importância da probabilidade e estatística

Curso de IA

Prof. MSc. Mariannys Rodriguez



mariannys.gasca@idp.edu.br



www.linkedin.com/in/mariannys-rodriguez-gasca

Resumo

- Nesta aula de Ciência de Dados, aprenderemos os fundamentos da ciência de dados e entenderemos como ela pode ser aplicada para resolver problemas do mundo real.
- Também veremos como os dados são coletados, limpos, analisados e modelados para gerar conhecimento útil.

O que é data science?

É uma área interdisciplinar que combina técnicas de estatística, matemática, ciência da computação e outras áreas para **extrair conhecimento** de dados.

Ela pode ser usada para resolver diversos problemas, desde a previsão da demanda de produtos até a detecção de fraudes em transações financeiras.


As aplicações da ciência de dados são infinitas, e seu objetivo é sempre extrair insights valiosos dos dados para tomar decisões melhores e mais precisas.

Conceitos de Data Science

Dados: Qualquer evento que pode ser armazenado em formato digital, incluindo texto, números, imagens, vídeo ou filmes, áudio, software, algoritmos, equações, animações, modelos, simulações, etc.

Informação: Conjuntos de dados significativos e úteis para humanos em processos como tomada de decisão.

Item Number	Product Description	Brand	Price
006	Pasta	Barilla	\$0.99
003	Eggs	Farm Fresh	\$1.79
010	Coffee	Folgers	\$4.49
008	Bananas	Chiquita	\$0.69
002	Bread	Wonder	\$1.49
005	Rice	Uncle Ben's	\$3.49
009	Cereal	Kellogg's	\$3.99
004	Chicken	Tyson	\$5.99
001	Milk	Nestlé	\$2.99
007	Apples	Washington	\$1.29



Information	Values
Total Items	10 items
Average Price	\$2.38
Maximum Price	\$5.99 (Chicken)
Minimum Price	\$0.69 (Bananas)
Total Brands	9 brands

Dados

Informação

Aplicações nos Negocios

Data


Quantidade e valor das vendas por produto



Informações demográficas do cliente



Canais de marketing usados para promover produtos



Informação

Ajuda a empresa a identificar quais produtos são **mais lucrativos** e quais precisam de melhorias de marketing ou design para aumentar as vendas.

Ajuda a identificar quais segmentos de clientes têm o **maior potencial** de compra e quais produtos ou promoções são mais relevantes para cada segmento.

Ajuda a empresa a identificar quais **canais** (marketing por e-mail, mídia social e publicidade em mecanismos de busca) são **mais eficazes** na geração de vendas e quais precisam de investimento adicional.

Conhecimento necessário

Conhecimento básico de **estatística** (média, desvio padrão, histogramas).



Conhecimento básico de **álgebra linear** (vetores, matrizes, operações com matrizes).



Conhecimento básico de **programação** (variáveis, operadores, condicionais, laços).



Paradigmas da Ciência:


1. Empírico: Baseado em observação direta e experimentação.



2. Teórico: Desenvolvimento de teorias a partir de princípios fundamentais.

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{4\pi G\rho}{3} - K\frac{c^2}{a^2}$$

3. Computacional: Utiliza modelos computacionais e simulações.



4. Focado em Dados: Enfatiza a coleta e a análise de grandes volumes de dados.



Processo de Data Science

Definição do Problema:

Defina claramente a questão ou o problema a ser abordado.

Coleta de Dados:

Reúna dados relevantes de diversas fontes.

Limpeza de Dados:

Prepare os dados removendo inconsistências e tratando valores ausentes.

Exploração de Dados:

Analise os dados para identificar padrões e insights iniciais.

Modelagem:

Aplique técnicas de modelagem e análise de dados para obter insights mais profundos.


Interpretação:

Interpretar os resultados e avaliar a eficácia do modelo.

Comunicação:

Apresente as descobertas de forma clara e visual para diversos públicos.

Os 5 Vs do Big Data



Conseguem pensar em um exemplo de dado que tenha muito volume, muita velocidade e variedade, mas que talvez não tenha muito valor?

Aplicações do Data Science

Ciência de Dados é uma disciplina versátil e poderosa, com aplicações em diversos campos. Vamos explorar alguns exemplos práticos de como a Ciência de Dados está sendo usada para impulsionar a inovação e melhorar os resultados em diferentes setores.

Setor de Saúde:

Análise de dados clínicos para identificar **padrões em doenças** e aprimorar diagnósticos. Previsão de tendências de saúde da população para planejar recursos médicos e prevenir epidemias. Uso de algoritmos de Aprendizado de Máquina para auxiliar em descobertas médicas e no desenvolvimento de medicamentos.



Setor Financeiro:

Deteção de fraudes em transações financeiras por meio de modelos preditivos. **Análise de risco** de crédito para avaliar a probabilidade de inadimplência do cliente. **Previsão** de tendências de mercado para auxiliar estratégias de investimento.



Aplicações do Data Science

Setor de Marketing e Varejo:

Personalização de recomendações de produtos com base nos hábitos de compra dos clientes. **Segmentação** de clientes para melhor direcionar campanhas de marketing. **Análise de sentimentos** em mídias sociais para entender a percepção do consumidor sobre produtos e marcas.



Setor de Transporte e Logística:

Otimização de **rotas** de entrega para reduzir custos e prazos de entrega. Análise de dados de sensores em veículos para aprimorar a **manutenção preventiva**. Previsão de demanda para planejar estoque e suprimentos com eficiência.



Funções na equipe de Data Science

Data Scientist: analisa dados, constrói modelos e extrai insights.

Data Engineer: cuida da infraestrutura, garante que os dados cheguem limpos e organizados.

Data Analyst: transforma dados em relatórios e dashboards para tomada de decisão.

Machine Learning Engineer: coloca os modelos de IA para rodar no mundo real.



Exploração de dados de experiência prática

Objetivo:

- ✓ Exploraremos a visualização de dados em Ciência de Dados e identificaremos padrões e insights.
- ✓ Descobriremos a importância da exploração de dados em Ciência de Dados.
- ✓ Aprenderemos como a "análise de dados" auxilia na identificação de padrões e tendências.

Você receberá dois conjuntos de dados: (i) Dados de Vendas e (ii) Dados de Preferências de Filmes.

A turma será dividida em dois grupos.

Cada grupo trabalhará com um conjunto de dados para exploração.

Exploração de dados de experiência prática

Etapa 01: Analisar o conjunto de dados

Dataset 1: Dados de vendas

Product	Salesperson	Quantity Sold	Total Revenue (R\$)
T-shirt	John	50	500
T-shirt	Maria	30	300
Pants	John	20	800
Pants	Maria	15	600
Shoes	John	10	1500
Shoes	Maria	5	750

- ✓ Sugestões de gráficos:
- ✓ Gráfico de barras: Compare a quantidade vendida de cada produto ou a receita total gerada por cada vendedor.
- ✓ Gráfico de pizza: Mostre a proporção de vendas de cada produto ou de cada vendedor.

Etapa 02: Apresente suas descobertas

Dataset 2: Dados de preferências de filmes

Person	Movie 1	Movie 2	Movie 3	Movie 4	Movie 5
John	Yes	No	Yes	Yes	No
Maria	Yes	Yes	Yes	No	Yes
Peter	No	No	Yes	Yes	No
Sofia	Yes	Yes	No	No	No
Lucas	No	Yes	Yes	Yes	Yes

- ✓ Sugestões de gráficos:
- ✓ Gráfico de barras: Compare o número de respostas "Sim" e "Não" para cada filme.
- ✓ Gráfico de pizza: Mostre a proporção de respostas "Sim" e "Não" para um filme específico.



**INSTITUTO BRASILEIRO DE ENSINO,
DESENVOLVIMENTO E PESQUISA**

mariannys.rgasca@gmail.com