

Compreendendo Dados: tendência central e dispersão

Curso de IA

Prof. MSc. Mariannys Rodriguez



mariannys.gasca@idp.edu.br



www.linkedin.com/in/mariannys-rodriguez-gasca

Resumo


- Nesta aula de análise de dados, revisaremos os conceitos de análise univariada em Ciência de Dados.
- Medidas de tendência central: média, mediana, moda, quartis
- Medidas de dispersão: variância e desvio padrão
- Representações gráficas: histograma, boxplot, pie chart, violin plot

Análise univariada


- ✓ A análise univariada é o estudo de uma única variável por vez na Ciência de Dados.
- ✓ Ela desempenha um papel crucial na compreensão de variáveis individuais e seus atributos.
- ✓ Alguns exemplos comuns de variáveis individuais que podem ser analisadas: idade, gênero, altura, peso, valor de vendas, categoria de produto, etc.




Violin



Density



Histogram



Boxplot



Ridgeline



Beeswarm

Medidas de Tendência Central e Dispersão

✓ Tendência Central.

- Média: Calculada pela soma de todos os valores e dividida pelo número de observações.
- Moda: O valor que ocorre com mais frequência.
- Mediana: O valor médio quando os dados são ordenados.
- Quartis: Valores que dividem um conjunto de dados ordenado em quatro partes iguais, cada uma representando 25% dos dados.

✓ Dispersão.

- Variância e Desvio Padrão: Mostram o quanto os dados se desviaram da média.

Ferramentas

Linguagens: Python, R, SQL.

Bibliotecas: Pandas, NumPy, Scikit-learn, TensorFlow.

Visualização: Power BI, Tableau, Matplotlib, Seaborn.


Ambientes: Jupyter Notebook, Google Colab.



Definição de Histograma

- ✓ Um histograma é uma representação gráfica da distribuição de frequência de um conjunto de dados.
- ✓ Ele consiste em barras, onde a altura de cada barra representa a frequência dos pontos de dados (contagem de observações) dentro de um intervalo específico.
- ✓ Isso é particularmente útil para compreender padrões, tendências e discrepâncias nos dados.

Distribution of property sales: January 2013 to September 2019



Exemplo de histograma

- ✓ Imagine que você está colaborando com um posto de gasolina local e recebeu a responsabilidade de analisar os dados relacionados à quantidade de gasolina que os clientes abastecem em seus veículos.
- ✓ Esses dados são vitais para entender o comportamento do cliente e otimizar a gestão de estoque.



Exemplo de histograma

- ✓ Coletamos dados referentes a um período específico, registrando a frequência com que os clientes abasteciam seus tanques com quantidades variadas de gasolina.
- ✓ Os dados foram divididos em intervalos: 5 a 10 litros, 10 a 15 litros, 15 a 20 litros, 20 a 25 litros e 25 a 30 litros. As respectivas frequências para esses intervalos são as seguintes:

Quantidade de Litros de Gasolina	Frequência
5 ┤ 10	20
10 ┤ 15	30
15 ┤ 20	25
20 ┤ 25	15
25 ┤ 30	10
Total	100

Código do Histograma


✓ Para compreender e comunicar melhor essa distribuição, geramos um histograma.

```
import matplotlib.pyplot as plt

# Intervalos de litros abastecidos
intervals = ['5-10', '10-15', '15-20', '20-25', '25-30']
frequencies = [20, 30, 25, 15, 10]

## Criando o histograma
plt.bar(intervals, frequencies)

plt.xlabel('Filled Liters Interval')
plt.ylabel('Frequency')
plt.title('Histogram of Number of Liters of Gasoline Filled')
plt.show()
```



Código do Histograma


```
import seaborn as sns
import matplotlib.pyplot as plt

# Example data
data = [3, 5, 5, 7, 8, 8, 8, 9, 10, 11,
        12, 12, 12, 14]

# Create the histogram using Seaborn
sns.histplot(data, color='blue',
             bins=10)


# Add title and axis labels
plt.title('Example Histogram')
plt.xlabel('Values')
plt.ylabel('Frequency')

# Show the plot
plt.show()
```




Box Plot

- ✓ O Box Plot é uma representação gráfica que mostra a distribuição de um conjunto de dados.
- ✓ Destacando medidas estatísticas importantes, como mediana, quartis, valores mínimos e máximos, bem como potenciais valores discrepantes.



Box Plot


- ✓ Ao organizar os dados em ordem crescente, podemos analisar os quartis dos dados.



$Q_2 = \textit{median}$


Box Plot

Elementos do Box Plot



Min/Max
tolerated range(Whiskers)

Without outliers



Exemplo de Box Plot


Imagine uma pesquisa que coletasse as idades de 20 pessoas.

Idades: 46, 34, 31, 54, 45, 45, 80, 45, 37, 46, 42, 48, 42, 37, 37, 30, 52, 34, 54, 54.



Exemplo de Box Plot


✓ O primeiro passo é colocar as idades em ordem crescente e calcular as medidas centrais.



Exemplo de Box Plot

✓ Imagine uma pesquisa que coletasse as idades de 20 pessoas em ordem crescente.

30	1st
31	2nd
34	3rd
34	4th
37	5th
37	6th
42	7th
42	8th
45	9th
45	10th
45	11th
46	12th
46	13th
48	14th
50	15th
52	16th
54	17th
54	18th
54	19th
80	20th



80
Outliers


Código do Box Plot

✓ Para compreender e comunicar melhor essa análise, geramos um Box Plot.

```
import matplotlib.pyplot as plt

# Age data
ages = [30, 31, 34, 34, 37, 37, 42, 42, 45, 45, 45, 46,
        46, 48, 50, 52, 54, 54, 54, 80]

# Creating the box plot
plt.boxplot(ages)
plt.xlabel('Ages')
plt.ylabel('Years')
plt.title('Box Plot of Ages')
plt.show()
```



Código do Box Plot


```
import seaborn as sns
import matplotlib.pyplot as plt

# Example data
data = [10, 12, 15, 18, 20, 22, 25, 35, 100]

# Create the box plot
sns.boxplot(data=data)

# Add title and axis labels
plt.title('Univariate Box Plot')
plt.ylabel('Values')

# Show the plot
plt.show()
```



Pie chart

✓Ele usa fatias de um círculo para representar a proporção ou porcentagem de cada categoria.


```
import matplotlib.pyplot as plt

# Data for the pie chart
categories = ['Category 1', 'Category 2',
             'Category 3', 'Category 4', 'Category 5']
values = [15, 30, 20, 10, 25]

# Creating the pie chart
plt.pie(values, labels=categories,
        autopct='%1.1f%%', startangle=90)

# Adding title
plt.title('Example Pie Chart')

# Displaying the pie chart
plt.show()
```



Violin Plot

✓ Ela representa uma variável ou categoria e mostra informações sobre a densidade de valores em diferentes regiões, a mediana, os quartis e possíveis valores discrepantes.


```
import seaborn as sns
import matplotlib.pyplot as plt

# Sample data for the violin plot
data = [10, 20, 30, 30, 40, 40, 40, 50, 50, 60,
        70, 80, 90, 100, 110, 120, 130, 140, 150]

# Creating the violin plot
sns.violinplot(data=data)

# Adding title
plt.title('Example Violin Plot')

# Displaying the violin plot
plt.show()
```



Atividade

- ✓ Aplique os conceitos de Análise Univariada a um conjunto de dados simples criado por você.
- ✓ Etapa 1: Crie uma conta no Google Colab;
- ✓ Etapa 2: Proponha um contexto para uma empresa e estime valores para seu conjunto de dados;
- ✓ Etapa 3: Utilize códigos Python para auxiliar neste processo;
- ✓ Etapa 4: Aplique pelo menos 3 análises diferentes estudadas no conjunto de dados.



**INSTITUTO BRASILEIRO DE ENSINO,
DESENVOLVIMENTO E PESQUISA**

mariannys.rgasca@gmail.com