

Análise multivariada

Curso de IA

Prof. MSc. Mariannys Rodriguez





 mariannys.gasca@idp.edu.br

 www.linkedin.com/in/mariannys-rodriguez-gasca

O que é Análise Multivariada?


- ✓ É uma técnica poderosa em ciência de dados, usada para **explorar, analisar e compreender** as relações entre múltiplas variáveis simultaneamente.
- ✓ Em conjuntos de dados do mundo real, frequentemente temos múltiplas variáveis que interagem e se influenciam mutuamente.
- ✓ Ao considerar múltiplas variáveis em conjunto, podemos obter **insights mais profundos** e **revelar padrões** que podem não ser aparentes ao analisar variáveis individuais.



O que é Análise Multivariada?

Exemplo:


Explorar variáveis que influenciam os preços dos apartamentos, considerando variáveis como localização, metragem quadrada e dados demográficos do bairro.



O que é Análise Multivariada?

Exemplo:


Em marketing, você pode observar como a variável “dinheiro gasto em publicidade” impacta a variável “número de vendas”.



O que é Análise Multivariada?

Exemplo:

No setor da saúde, você pode querer explorar se existe uma correlação entre “Horas diárias de exercício” e “nível de colesterol”.



Tipos de dados e visualizações comuns

Na análise multivariada, encontramos vários tipos de dados, cada um exigindo técnicas de visualização específicas para uma exploração eficaz.

Dados Categóricos


Representam categorias ou grupos.



E.g.: Gênero

Dados Numéricos

Envolvem grandezas mensuráveis.



E.g.: dados meteorológicos

Sugestão de gráfico

Ranking



Barplot



Spider / Radar



Wordcloud




Parallel



Lollipop



Circular Barplot



Table


Part Of A Whole



Treemap



Venn Diagram



Donut




Pie Chart



Dendrogram



Circular Packing



Waffle


Evolution




Line chart



Area chart



Stacked Area



Streamgraph



Candlestick



Timeseries

Sugestão de gráfico

Map



Map



Choropleth



Hexbin



Cartogram



Connection



Bubble

Flow



Chord Diagram




Network



Sankey



Arc Diagram



Edge Bundling

General Knowledge



Colors



Interactivity




Animation



Cheat sheets



Caveats




3D




Statistics



Sugestão de gráfico



Sugestão de gráfico




Sugestão de gráfico



Gráficos de dispersão para análise multivariada

- ✓ Diagramas de dispersão são representações gráficas usadas para **explorar a relação entre duas variáveis numéricas**.
- ✓ Eles nos ajudam a entender como mudanças em uma variável podem influenciar outra.

Cada **eixo** representa uma variável numérica.



Os gráficos de dispersão podem mostrar padrões como **correlação positiva/negativa**, clusters ou outliers.

Cada ponto de dados no gráfico representa uma **observação**

Gráficos de dispersão para análise multivariada

✓ Titanic Dataset

Column	Description
PassengerId	Unique identification number for each passenger.
Survived	Indicates whether the passenger survived (1) or not (0).
Pclass	Ticket class of the passenger (1st, 2nd, or 3rd class).
Name	Name of the passenger.
Sex	Gender of the passenger (male or female).
Age	Age of the passenger.
SibSp	Number of siblings/spouses aboard the Titanic.
Parch	Number of parents/children aboard the Titanic.
Ticket	Ticket number.
Fare	Fare paid by the passenger.
Cabin	Cabin number where the passenger stayed.
Embarked	Port of embarkation (C = Cherbourg, Q = Queenstown, S = Southampton).

Gráficos de dispersão

```
import pandas as pd
import matplotlib.pyplot as plt

# Cargar conjunto de dados
from google.colab import files
uploaded = files.upload()


database =
pd.read_csv("titanic.csv")
# Crear o gráfico de dispersão
plt.scatter(database['Age'], database['Fare'],
alpha=0.5)
plt.title('Scatter Plot: Age vs. Fare')
plt.xlabel('Age')
plt.ylabel('Fare')
plt.show()
```



Gráficos de dispersão

Conclusões:

- ✓ Há um conjunto de pontos com tarifas mais baixas.
- ✓ A idade dos passageiros varia bastante.
- ✓ Não há um padrão de relação linear aparente entre idade e tarifa.
- ✓ Existem alguns pontos fora da curva com tarifas muito altas, especialmente entre passageiros mais jovens.



Gráficos de dispersão

Possíveis combinações considerando o conjunto de dados do Titanic:


- Idade e Sobrevivência: Verifique se há alguma tendência entre a idade dos passageiros e sua taxa de sobrevivência.
- Classe e Tarifa: Analise como as tarifas variam entre as diferentes classes de passageiros.
- Idade e Classe: Examine se há alguma associação entre a idade dos passageiros e a classe em que estavam.
- Idade e Gênero: Explore como a idade se relaciona com o gênero dos passageiros.

Gráficos de dispersão

- Idade e número de pais/filhos (Parch) a bordo: examine se a idade influencia o número de pais/filhos a bordo.
- Porto de embarque e tarifa: analise como as tarifas diferem entre os portos de embarque.
- Gênero e sobrevivência: investigue a relação entre o gênero dos passageiros e sua taxa de sobrevivência.


Mapas de calor para análise multivariada

- Mapas de calor são representações gráficas que usam **cores para exibir as relações** entre múltiplas variáveis em um formato matricial.
- Mapas de calor permitem a comparação de relações entre **múltiplas variáveis em um único gráfico**. Isso ajuda a entender como diferentes variáveis se relacionam entre si.



Coefficiente de correlação (r)?

- ✓ O coeficiente de correlação (r) é uma medida estatística que avalia a **relação linear entre duas variáveis**.
- ✓ Ele quantifica a direção e a força dessa relação, indicando se as variáveis tendem a **aumentar ou diminuir juntas**.
- ✓ O coeficiente de correlação de Pearson varia de -1 a +1:
 - +1: Indica uma **correlação positiva perfeita**, ou seja, quando uma variável aumenta, a outra também aumenta na mesma proporção.
 - -1: Indica uma **correlação negativa perfeita**, ou seja, quando uma variável aumenta, a outra diminui na mesma proporção.
 - 0: Indica que **não há correlação** linear entre as variáveis. Elas não têm uma relação linear óbvia.



$ r $ (modulus)	Interpretation
$ r < 0.4$	Weak correlation
$0.4 \leq r < 0.7$	Mild correlation
$ r \geq 0.7$	Strong correlation

Mapas de calor

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt


# Cargar conjunto de dados
from google.colab import files
uploaded = files.upload()

database = pd.read_csv("titanic.csv")

# Seleccionamos variáveis numéricas para análise
de correlação
variables = ['Age', 'Fare', 'SibSp', 'Parch',
'Survived', 'Pclass', 'Sex', 'Embarked']

# Calcular matriz de correlação
correlation_matrix = database[variables].corr()

# Criar o heatmap
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', center=0)
plt.title('Heatmap: Correlations between Variables')
plt.show()
```



Mapas de calor


Conclusão:

✓ À medida que o gênero muda de 0 (masculino) para 1 (feminino), as mortes diminuem.

	Male	Female
Sex	0	1
	Not	Yes
Survived	0	1

✓ Quanto maior a classe, menor a tarifa.

	First	Second	Third
Classes	1	2	3
Fare	Higher	Mild	Lower



Conclusão

- Utilizando gráficos de dispersão e mapas de calor, exploramos duas técnicas de visualização poderosas para análise multivariada, revelando **relações e padrões** em dados complexos.
- **Gráficos de Dispersão:** Visualizam relações entre duas variáveis, ajudando-nos a entender correlações e tendências potenciais.
- **Mapas de Calor:** Exibem correlações e padrões de dados por meio de matrizes codificadas por cores, auxiliando na rápida identificação de insights.

Atividade

- Analise o conjunto de dados do Titanic. Siga os seguintes passos.
<https://www.kaggle.com/datasets/yasserh/titanic-dataset/data>
- **Etapa 1 | Formulação da Hipótese**
- Formule uma hipótese com base no conjunto de dados. Por exemplo, "Existe uma correlação entre “X” e “Y”?" (Os slides 15 e 16 podem ajudar)
- **Etapa 2 | Exploração de Dados**
- Crie gráficos de dispersão para visualizar as relações entre as variáveis selecionadas.
- **Etapa 3 | Interpretação**
- Analise o gráfico de dispersão para extrair insights. Por exemplo: O gráfico apoia ou refuta sua hipótese?
- **Etapa 4 | Criação do Mapa de Calor**
- Crie um mapa de calor para explorar as correlações entre diferentes variáveis.
- **Etapa 5 | Discussão**
- Discuta suas descobertas. Por exemplo: O mapa de calor revelou alguma relação inesperada?
- **Etapa 6 | Conclusões**
- Conclua se sua hipótese foi apoiada pela análise e quais insights você obteve com as visualizações.



**INSTITUTO BRASILEIRO DE ENSINO,
DESENVOLVIMENTO E PESQUISA**

mariannys.rgasca@gmail.com